UNIVERSIDAD PERUANA UNIÓN
FACULTAD DE INGENIERIA Y ARQUITECTURA
Escuela Profesional de Ingeniería de Sistemas



Comparación de Métodos de Generación de Datos Sintéticos para la Clasificación Fina de Requerimientos No Funcionales: EDA, SMOTE-Tomek, TAOS e Inteligencia Artificial Generativa

Por:
Alessandro Pastor Mamani Mamani
Andres Lino Montes Mamani
Cabana Sulca Cristian
Curso : Investigación IV

Asesor:
Fredy Abel Huanca Torres

Fecha: October 2, 2026

Contents

1 Identificación del problema **3**

2 Justificación **4**
2.1 Relevancia teórica 4
2.2 Relevancia metodológica 4
2.3 Relevancia práctica 4

3 Estado del arte **4**
3.1 Fase 1 (2017–2020): Aprendizaje automático clásico 4
3.2 Fase 2 (2021–2023): Aprendizaje profundo 5
3.3 Fase 3 (2025): Transformers y aumentación de texto 5
3.4 Fase 4 (emergente): IA generativa en ingeniería de requerimientos 5

4 Marco teórico **6**
4.1 Requerimientos No Funcionales 6
4.2 BERT como clasificador de referencia 6
4.3 EDA: Easy Data Augmentation 6
4.4 SMOTE-Tomek 6
4.5 TAOS: TextAttack Oversampling 7
4.6 Métricas para datos desbalanceados 7

5 Metodología **8**
5.0.1 Enfoque de la Investigación 8
5.0.2 Nivel de Investigación 8
5.0.3 Método de Investigación 9
5.0.4 Método de Trabajo 9
5.0.5 Diseño de la Investigación 11
5.0.6 Población y Muestra 11
5.0.7 Técnicas e Instrumentos de Recolección de Datos 11
5.0.8 Técnicas de Análisis de Datos 12
5.0.9 Técnicas de Muestreo 13
5.1 Aspectos Éticos 13
5.1.1 Anonimato y Confidencialidad 13
5.1.2 Uso Responsable de los Modelos de IA Generativa 13
5.1.3 Reproducibilidad y Transparencia 14
5.1.4 Riesgo Ético Nulo 14
5.1.5 Conflictos de Interés 14
5.2 Cronograma de actividades 14
5.3 Presupuesto Proyectado 14

6 Referencias Bibliográficas **17**

1 Identificación del problema

Los Requerimientos No Funcionales (NFR) —seguridad, mantenibilidad, portabilidad, tolerancia a fallos, usabilidad— determinan en gran medida el éxito o fracaso de los proyectos de software, especialmente cuando no son identificados de forma oportuna durante las fases tempranas del ciclo de vida del desarrollo ClelandHuang2007-PROMISE, Kurtanovic2017-SupervisedML, Wiegers2013-SWRequirements, Hussain2020-NFRClassification. Su clasificación automática a partir de documentos de especificación permite anticipar riesgos de diseño y asignar recursos de verificación de manera eficiente; sin embargo, esta tarea enfrenta un obstáculo estructural que la literatura no ha resuelto completamente: el **desbalance extremo de clases** Johnson2019-ClassImbalance, Fernandez2018-SMOTE.

El dataset de referencia para esta tarea, PROMISE NFR ClelandHuang2007-PROMISE, ClelandHuang2007-Zenodo, agrupa 1,534 requerimientos etiquetados en 12 categorías. Su distribución está fuertemente sesgada: en el conjunto de entrenamiento utilizado en esta investigación (train.csv del repositorio oficial de TAOS), la clase mayoritaria (Funcionalidad, F) concentra 557 muestras, mientras que la más escasa (Portabilidad, PO) cuenta con únicamente 5. Esta proporción de **156:1** configura uno de los escenarios de desbalance más severos reportados en la literatura de clasificación de texto con técnicas de aprendizaje profundo Johnson2019-ClassImbalance.

Bajo esta condición, los clasificadores desarrollan un **sesgo estructural** hacia las clases frecuentes al optimizar funciones de pérdida global Johnson2019-ClassImbalance, Fernandez2018-SMOTE, Sokolova2009-MacroMicro: maximizan la exactitud agregada prediciendo casi siempre las categorías mayoritarias, mientras que clases críticas como Mantenibilidad (MN), Legal (L), Tolerancia a Fallos (FT) y Portabilidad (PO) resultan sistemáticamente indetectables, con valores de F1-score iguales a cero en los experimentos de referencia BenAmmar2025-TAOS.

El trabajo más reciente en este dominio, TAOS (*TextAttack Oversampling*) BenAmmar2025-TAOS, reportó un incremento del F1-score ponderado de 0.75 a 0.93 mediante técnicas de aumentación de texto multi-nivel basadas en el framework TextAttack Morris2020-TextAttack sobre un clasificador BERT Devlin2019-BERT. No obstante, ese estudio comparó su propuesta **exclusivamente contra un baseline sin balanceo**, sin contrastarla frente a técnicas de aumentación consolidadas en la literatura de NLP. Es posible que métodos más simples —como EDA, con más de 3,000 citas en la literatura de NLP Wei2019-EDA, Feng2021-SurveyDA, Shorten2021-TextAugSurvey— o enfoques cualitativamente superiores en generación semántica —como los modelos de lenguaje de gran escala Brown2020-GPT3, OpenAI2023-GPT4, Anthropic2024-Claude— produzcan resultados comparables o mejores con menor costo computacional. Sin una comparación controlada bajo condiciones idénticas, no puede afirmarse que TAOS sea el método óptimo para este problema.

En consecuencia, la presente investigación formula la siguiente pregunta: *¿Cuál es la estrategia óptima de generación de datos sintéticos para mejorar la clasificación fina de NFR con desbalance extremo, al comparar Baseline, EDA, SMOTE-Tomek y TAOS bajo condiciones controladas e idénticas sobre un mismo clasificador BERT?*

2 Justificación

2.1 Relevancia teórica

Esta investigación realiza la primera comparación controlada de métodos de aumentación de datos aplicados a la clasificación fina de NFR, fijando el clasificador (BERT base uncased Devlin2019-BERT), el dataset (PROMISE NFR ClelandHuang2007-PROMISE) y el protocolo de evaluación (validación cruzada estratificada de 5 pliegues) como variables constantes. Este diseño garantiza la validez interna del experimento Wohlin2012-Empirical, Hevner2004-DSR: cualquier diferencia observada en las métricas se atribuye exclusivamente al método de generación de datos, produciendo evidencia científica sólida y directamente accionable para la selección fundamentada de estrategias de balanceo.

2.2 Relevancia metodológica

El estudio extiende técnicas consolidadas hacia escenarios no explorados: evalúa por primera vez EDA Wei2019-EDA en la clasificación multi-clase de 12 categorías NFR con BERT, y extiende SMOTE-Tomek Chawla2002-SMOTE, Batista2004-SMOTETomek, Rubaidi2023-SMOTETomek —hasta ahora restringido al escenario binario en este dominio— al espacio de embeddings contextuales BERT de 768 dimensiones Reimers2019-SentenceBERT. Asimismo, incorpora el análisis de estabilidad entre pliegues como criterio complementario de evaluación, un aspecto omitido en los estudios previos del área Dietterich1998-McNemar.

2.3 Relevancia práctica

Los resultados ofrecen a los equipos de ingeniería de requerimientos criterios objetivos para elegir la técnica de balanceo según su prioridad: equidad entre clases, rendimiento global o estabilidad en producción. Dado que los NFR no detectados a tiempo generan sobrecostos significativos en las fases tardías del desarrollo Wiegers2013-SWRequirements, Knauss2018-Survey, disponer de clasificadores capaces de reconocer las categorías minoritarias tiene impacto directo en la calidad del software producido.

3 Estado del arte

La investigación en clasificación automática de NFR ha evolucionado en cuatro generaciones de métodos, cada una con avances y limitaciones específicas frente al problema del desbalance.

3.1 Fase 1 (2017–2020): Aprendizaje automático clásico

Los primeros estudios emplearon algoritmos clásicos —SVM, Multinomial Naive Bayes y kNN— combinados con representaciones vectoriales basadas en TF-IDF o *word embeddings* estáticos Kurtanovic2017-SupervisedML, Dias2020-SoftwareReqML, Hussain2020-NFRClassification,

Mikolov2013-Word2Vec. Estos trabajos demostraron la viabilidad de la clasificación automática en el escenario binario (Funcional vs. No Funcional), pero ninguno abordó el desbalance de clases como variable experimental, por lo que las categorías minoritarias permanecían sistemáticamente ignoradas.

3.2 Fase 2 (2021–2023): Aprendizaje profundo

La segunda generación adoptó arquitecturas de aprendizaje profundo. Rahimi2021-TwoPhase propusieron un *ensemble* de dos fases que combina BiLSTM, GRU y CNN Hochreiter1997-LSTM, Kim2014-CNN, logrando un 93.4% de *accuracy* en clasificación multi-clase, aunque sin tratamiento explícito del desbalance. En paralelo, Rubaidi2023-SMOTETomek aplicaron SMOTE-Tomek Chawla2002-SMOTE, Batista2004-SMOTETomek, Lemaitre2017-ImbalancedLearn por primera vez en el dominio de la clasificación de requerimientos, alcanzando un F1 de 76.16%; sin embargo, su evaluación se limitó al escenario binario, sin extenderse a las 12 categorías finas del PROMISE NFR.

3.3 Fase 3 (2025): Transformers y aumentación de texto

La llegada de BERT Devlin2019-BERT marcó el estado del arte actual. BenAmmar2025-TAOS presentaron TAOS, que combina cinco técnicas de aumentación del framework TextAttack Morris2020-TextAttack, Kobayashi2018-ContextualAug validadas mediante un filtro semántico BERT auxiliar, elevando el F1 ponderado de 0.75 a 0.93 y recuperando las cuatro clases antes indetectables (MN, L, FT, PO). Su limitación crítica es que la comparación se realizó únicamente contra un baseline sin aumentación: EDA, SMOTE-Tomek y la IA generativa nunca fueron evaluados como competidores directos bajo el mismo clasificador.

3.4 Fase 4 (emergente): IA generativa en ingeniería de requerimientos

GPT-4 OpenAI2023-GPT4 y Claude Anthropic2024-Claude han demostrado capacidad para generar texto técnico especializado mediante *prompting* estructurado Brown2020-GPT3, Liu2023-PromptSurvey, Wei2022-EmergentAbilities en dominios como derecho, medicina y programación. Trabajos recientes en clasificación de sentimientos y detección de intenciones han validado su uso como herramienta de aumentación de datos Dai2023-AugGPT, Yoo2021-GPT3DA, Ubani2023-ZeroShotDA, Jahan2021-SemanticFilter. No obstante, ningún estudio ha evaluado LLMs como mecanismo de *oversampling* para la clasificación de NFR, lo que constituye una brecha total en la literatura de ingeniería de requerimientos Moller2023-IsItWorth, Farroq2023-MultiLabel, Khurshid2022-NFRIoT.

4 Marco teórico

4.1 Requerimientos No Funcionales

Los NFR especifican atributos de calidad y restricciones del sistema —rendimiento, seguridad, usabilidad, mantenibilidad— en contraste con los requerimientos funcionales, que describen comportamientos Wiegers2013-SWRequirements, Knauss2018-Survey. El dataset PROMISE NFR ClelandHuang2007-PROMISE, ClelandHuang2007-Zenodo constituye el estándar de facto para evaluar su clasificación automática.

4.2 BERT como clasificador de referencia

BERT (*Bidirectional Encoder Representations from Transformers*) se fundamenta en el mecanismo de atención multi-cabeza Vaswani2017-Attention y el pre-entrenamiento mediante *masked language modeling* (MLM) sobre corpus masivos Devlin2019-BERT. A diferencia de las representaciones estáticas (*word2vec*, GloVe) Mikolov2013-Word2Vec, Pennington2014-GloVe, BERT genera representaciones contextuales que capturan el significado de cada token en función de su contexto bidireccional Rogers2020-BERTPrimer. El *fine-tuning* de BERT para clasificación en dominios especializados ha demostrado consistentemente superar a los enfoques clásicos y de aprendizaje profundo Sun2019-BERTFineTuning, Howard2018-ULMFiT. En esta investigación, BERT base uncased actúa como **clasificador de referencia único y constante** en todos los pipelines: cualquier diferencia en las métricas se atribuye exclusivamente al método de generación de datos Wohlin2012-Empirical.

4.3 EDA: Easy Data Augmentation

EDA Wei2019-EDA genera variantes de texto mediante cuatro operaciones léxicas simples: reemplazo de sinónimos (SR), inserción aleatoria (RI), intercambio aleatorio (RS) y eliminación aleatoria (RD). Su bajo costo computacional y sus mejoras consistentes en clasificación de texto la han convertido en una de las técnicas más citadas de la aumentación en NLP Feng2021-SurveyDA, Shorten2021-TextAugSurvey, Bayer2022-DataAugNLP.

4.4 SMOTE-Tomek

SMOTE Chawla2002-SMOTE genera muestras sintéticas por interpolación lineal entre vectores vecinos de la clase minoritaria; los enlaces de Tomek Batista2004-SMOTETomek eliminan posteriormente las muestras ambiguas de la frontera de decisión. En esta investigación, la técnica se aplica sobre los embeddings del token `[CLS]` de BERT (768 dimensiones) Reimers2019-SentenceBERT, Lemaitre2017-ImbalancedLearn, decodificando cada vector sintético al requerimiento real más cercano por similitud coseno para que el clasificador procese texto válido.

4.5 TAOS: TextAttack Oversampling

TAOS BenAmmar2025-TAOS combina cinco técnicas de aumentación del framework TextAttack Morris2020-TextAttack —a nivel de embeddings, listas de verificación, WordNet, intercambio de caracteres y EDA— validadas por un clasificador BERT auxiliar que filtra las aumentaciones semánticamente inconsistentes Kobayashi2018-ContextualAug. Es el método con mejores resultados publicados en la clasificación fina del PROMISE NFR.

4.6 Métricas para datos desbalanceados

La exactitud (*accuracy*) resulta engañosa bajo desbalance severo Sokolova2009-MacroMicro. Por ello se emplean: el **F1-score ponderado**, que promedia el F1 por clase ponderando por su frecuencia; el **F1-score macro**, que asigna igual peso a todas las clases y refleja directamente el desempeño en las categorías minoritarias; y el **Coeficiente de Correlación de Matthews** (MCC) Dietterich1998-McNemar, considerado el indicador más robusto para clasificación multi-clase desbalanceada. Complementariamente, la validación cruzada estratificada de 5 pliegues Wohlin2012-Empirical reporta cada métrica como media y desviación estándar, permitiendo evaluar tanto el desempeño esperado como la estabilidad de cada método.

5 Metodología

La metodología define la estructura, los métodos y los procedimientos que guiarán el desarrollo de la presente investigación. En este estudio, se adopta una metodología orientada a la evaluación experimental controlada de técnicas de generación de datos sintéticos y su impacto en la clasificación automática de Requerimientos No Funcionales (NFRs), ya que busca producir evidencia empírica reproducible sobre qué estrategia de balanceo de clases es óptima para el dataset PROMISE NFR bajo condiciones experimentales idénticas BenAmmar2025-TAOS, Wei2019-EDA, Chawla2002-SMOTE.

5.0.1 Enfoque de la Investigación

El estudio se enmarca en un **enfoque cuantitativo**, sustentado en la medición objetiva del desempeño clasificatorio de modelos de aprendizaje profundo entrenados sobre datos sintéticos generados por diferentes métodos. Este enfoque permite comparar el impacto de cada estrategia de balanceo mediante indicadores numéricos estandarizados: F1-score macro, F1-score ponderado, precisión y recall por clase, y matrices de confusión individuales.

El carácter cuantitativo se refuerza por el uso de pruebas estadísticas formales —específicamente la prueba de McNemar— para determinar si las diferencias observadas en el desempeño entre métodos son estadísticamente significativas y no atribuibles al azar, lo que dota a la comparación de rigor científico más allá de la simple comparación de métricas Johnson2019-ClassImbalance, BenAmmar2025-TAOS.

5.0.2 Nivel de Investigación

El nivel de investigación es **aplicativo–comparativo**.

- En su componente **aplicativo**, la investigación implementa y evalúa cuatro métodos de generación de datos sintéticos —EDA, SMOTE-Tomek, TAOS e IA Generativa (GPT-4 y Claude)— sobre el dataset PROMISE NFR con BERT base uncased como clasificador de referencia, generando conocimiento directamente aplicable al diseño de herramientas de análisis automatizado de documentos SRS BenAmmar2025-TAOS, Rahimi2021-TwoPhase.

- En su componente **comparativo**, el estudio evalúa sistemáticamente los cinco pipelines experimentales —Baseline, EDA, SMOTE-Tomek, TAOS e IAG— bajo condiciones idénticas, con el objetivo de determinar empíricamente cuál estrategia produce el mayor incremento en la detección de las clases minoritarias críticas Mantenibilidad (MN), Legal (L), Tolerancia a Fallos (FT) y Portabilidad (PO) Wei2019-EDA, Rubaidi2023-SMOTETomek.

Este nivel metodológico permite no solo replicar el estado del arte, sino avanzarlo mediante una comparación controlada que la literatura actual no ha realizado.

5.0.3 Método de Investigación

La investigación es de tipo **aplicada y empírica**, orientada a la resolución de un problema técnico concreto —el desbalance extremo de clases en la clasificación de NFRs— mediante la construcción, implementación y evaluación comparativa de cinco pipelines experimentales.

Se integran dos métodos complementarios:

- **Método de la Ciencia del Diseño (*Design Science Research* – DSR):** Se emplea para desarrollar los artefactos tecnológicos centrales de esta tesis —los pipelines de generación de datos sintéticos y el clasificador BERT fine-tuned— siguiendo las fases propuestas por Hevner et al. (2004): identificación del problema, diseño del artefacto, evaluación, contribución y comunicación. Este enfoque se alinea con las prácticas actuales en Ingeniería de Requerimientos asistida por IA y en el diseño de sistemas de NLP para dominios técnicos BenAmmar2025-TAOS, Morris2020-TextAttack.

- **Método Experimental Controlado:** Se aplica para garantizar la validez interna de la comparación multi-método. Todas las variables experimentales excepto el método de generación de datos son mantenidas constantes: dataset (PROMISE NFR, mismo *split* 70/30), clasificador (BERT base uncased), hiperparámetros de entrenamiento (3 épocas, batch size 8, AdamW, *learning rate* estándar Transformers) y protocolo de evaluación. Este diseño garantiza que las diferencias observadas en el F1-score sean causalmente atribuibles al método de balanceo Johnson2019-ClassImbalance, BenAmmar2025-TAOS.

5.0.4 Método de Trabajo

El método de trabajo adoptado sigue una secuencia sistemática de seis fases orientadas a la comparación experimental de métodos de generación de datos sintéticos para la clasificación fina de NFRs BenAmmar2025-TAOS, Wei2019-EDA, Chawla2002-SMOTE.

1. **Preparación del entorno y replicación del baseline:** Configuración del entorno de experimentación reproducible (Python 3.10, PyTorch 2.x, Transformers 4.x, semilla fija `SEED=42`) y replicación del experimento baseline y TAOS del artículo original BenAmmar2025-TAOS sobre el dataset PROMISE NFR con BERT base uncased, verificando que los resultados reportados (F1-score ponderado de 0.75 y 0.93 respectivamente) sean reproducibles antes de proceder con los experimentos adicionales. Esta fase valida la integridad del entorno experimental y establece el punto de partida de toda la comparación.

2. **Generación de datos sintéticos con EDA:** Aplicación de EDA Wei2019-EDA mediante las cuatro operaciones lingüísticas —reemplazo de sinónimos (SR), inserción aleatoria (RI), intercambio aleatorio (RS) y eliminación aleatoria (RD)— sobre las instancias de las 11 clases minoritarias del PROMISE NFR. La generación se repite iterativamente hasta alcanzar un tamaño de clase comparable al producido por TAOS. La calidad del texto generado se evalúa mediante similitud semántica coseno (con

sentence-transformers), Type-Token Ratio (TTR) y Self-BLEU, métricas que permiten medir la fidelidad semántica y la diversidad léxica de los datos sintéticos producidos.

3. **Generación de datos sintéticos con SMOTE-Tomek:** Extracción de los embeddings contextuales de la capa `[CLS]` de BERT para cada instancia del dataset de entrenamiento, y aplicación de SMOTE-Tomek Chawla2002-SMOTE sobre el espacio vectorial de dimensión 768 resultante. El algoritmo genera puntos sintéticos por interpolación entre vecinos en este espacio de alta dimensión y elimina pares Tomek para limpiar la frontera de decisión. La calidad de la generación se verifica mediante análisis de separabilidad en el espacio de embeddings (t-SNE y distancia inter-clase coseno).

4. **Generación de datos sintéticos con IA Generativa:** Diseño e implementación de un protocolo de *prompting* estructurado *few-shot* para la generación de requerimientos NFR sintéticos con GPT-4 (OpenAI API) y Claude (Anthropic API). El protocolo incluye: definición de la categoría objetivo, instrucciones de dominio específicas de IS, provisión de tres a cinco ejemplos reales de la clase como contexto, y parámetro de temperatura calibrado para balancear coherencia y diversidad. Cada requerimiento generado es filtrado automáticamente mediante similitud coseno (umbral ≥ 0.70) para retener únicamente instancias de calidad semántica aceptable, siguiendo el criterio de validación de TAOS BenAmmar2025-TAOS.

5. **Comparación experimental y análisis estadístico:** Entrenamiento de BERT base uncased sobre cada uno de los cinco datasets balanceados —Baseline, EDA, SMOTE-Tomek, TAOS, IAG (GPT-4 y Claude)— bajo configuración idéntica. Evaluación con el mismo conjunto de prueba para los cinco experimentos, reportando F1-score macro, F1-score ponderado, precisión y recall por clase, y matrices de confusión individuales. Las diferencias entre los modelos se someten a la prueba de McNemar para determinar su significancia estadística, con un nivel de confianza del 95%.

6. **Análisis de calidad de datos e interpretabilidad:** Análisis de correlación entre las métricas de calidad de los datos sintéticos (TTR, Self-BLEU, similitud coseno) y el F1-score *downstream* por clase, para identificar qué dimensiones de calidad predicen mejor la recuperación de las clases minoritarias críticas. Adicionalmente, se aplican técnicas de interpretabilidad LIME Ribeiro2016-LIME y SHAP Lundberg2017-SHAP sobre el mejor modelo identificado para explicar qué patrones lingüísticos y características semánticas determinan la clasificación de cada categoría NFR, transformando la caja negra del clasificador en conocimiento accionable para la Ingeniería de Requerimientos.

En síntesis, este procedimiento metodológico garantiza una comparación sistemática, controlada y reproducible de los cinco métodos de generación de datos, contribuyendo con evidencia empírica sólida al avance del campo de la clasificación automática de NFRs con desbalance extremo de clases BenAmmar2025-TAOS, Johnson2019-ClassImbalance.

5.0.5 Diseño de la Investigación

El diseño adoptado es **experimental, transversal y de tipo cuasi-experimental con grupo control**.

El componente **experimental** se materializa en la manipulación controlada de la única variable independiente del estudio —el método de generación de datos sintéticos— mientras se mantienen constantes todas las demás condiciones experimentales. El componente **transversal** se justifica porque todos los experimentos se ejecutan sobre el mismo dataset en el mismo periodo, sin seguimiento longitudinal. El componente **cuasi-experimental** reconoce que los datos de entrenamiento no son asignados aleatoriamente a condiciones, sino que se generan bajo procedimientos deterministas con semilla fija (`SEED=42`) para garantizar reproducibilidad BenAmmar2025-TAOS.

El **grupo control** del experimento es el pipeline Baseline: BERT base uncased entrenado sobre el dataset PROMISE NFR original sin ningún tratamiento de balanceo, cuyos resultados reportados en la literatura (F1-score ponderado de 0.75) sirven como referencia de comparación para los cuatro métodos de tratamiento BenAmmar2025-TAOS.

5.0.6 Población y Muestra

- **Población:** El conjunto completo de requerimientos de software etiquetados disponibles en la literatura de Ingeniería de Requerimientos para la tarea de clasificación multi-clase de NFRs. Esta población incluye múltiples datasets publicados en trabajos previos, de los cuales el PROMISE NFR es el más adoptado como benchmark estándar del dominio ClelandHuang2007-PROMISE, BenAmmar2025-TAOS.

- **Muestra:** El dataset **PROMISE NFR** ClelandHuang2007-PROMISE, compuesto por 1,534 requerimientos etiquetados distribuidos en 12 categorías, dividido en subconjunto de entrenamiento (1,073 instancias, 70%) y prueba (461 instancias, 30%), siguiendo exactamente el *split* utilizado por BenAmmar2025-TAOS para garantizar la comparabilidad directa de los resultados. La elección de este dataset es intencional y justificada: es el único benchmark del dominio con 12 clases de NFRs, con desbalance extremo documentado (278:1) y con resultados de referencia publicados para el mismo clasificador (BERT base uncased).

5.0.7 Técnicas e Instrumentos de Recolección de Datos

- **Fuente de datos primaria:** El dataset PROMISE NFR, disponible públicamente en el repositorio Zenodo ClelandHuang2007-PROMISE, constituye la única fuente de datos de esta investigación. Al tratarse de un dataset de referencia ya publicado y ampliamente validado en la literatura, no se requiere recolección de datos primarios adicionales.

- **Instrumentos de generación de datos sintéticos:**

  - **EDA:** Librería `nlpaug` o implementación directa de las cuatro operaciones EDA Wei2019-EDA con WordNet como léxico de sinónimos.

  - **SMOTE-Tomek:** Librería `imbalanced-learn` con parámetro `k_neighbors=5` para SMOTE, aplicado sobre embeddings BERT de dimensión 768 Chawla2002-SMOTE.
  - **TAOS:** Repositorio oficial del artículo (`github.com/boulbaba1981/TAOS`) BenAmmar2025-TAOS con el framework TextAttack Morris2020-TextAttack.
  - **IA Generativa:** API de OpenAI (modelo `gpt-4o`) y API de Anthropic (modelo `claude-sonnet-4-5-20251001`), con temperatura = 0.7 y protocolo de *prompting* few-shot diseñado específicamente para el dominio de IS.

- **Clasificador:** Modelo `bert-base-uncased` de la librería Transformers (Hugging Face), con *fine-tuning* supervisado sobre cada dataset balanceado bajo la configuración estándar reportada por BenAmmar2025-TAOS: 3 épocas, batch size 8, optimizador AdamW con *weight decay* = 0.01, longitud máxima de secuencia de 512 tokens.

- **Entorno computacional:** Los experimentos se ejecutarán en Google Colaboratory con GPU NVIDIA T4 (15 GB VRAM) o equivalente, con Python 3.10, PyTorch 2.x y semilla global fija (`SEED=42`) para reproducibilidad completa.

5.0.8 Técnicas de Análisis de Datos

El análisis se realizará en tres dimensiones complementarias:

- **Análisis de calidad de datos sintéticos:** Evaluación de los datos generados por cada método mediante tres métricas complementarias: (a) **similitud coseno** entre cada instancia sintética y sus instancias originales de la misma clase, usando modelos *sentence-transformers* (modelo `all-MiniLM-L6-v2`), para medir la fidelidad semántica; (b) **Type-Token Ratio (TTR)**, definido como el cociente entre el número de tipos léxicos únicos y el total de tokens, para medir la riqueza léxica de los datos sintéticos; y (c) **Self-BLEU**, calculado comparando cada instancia sintética contra las demás instancias de la misma clase, para medir la diversidad interna del conjunto generado BenAmmar2025-TAOS.

- **Análisis de desempeño clasificatorio:** Evaluación del F1-score macro, F1-score ponderado, precisión y recall por clase de cada uno de los cinco modelos BERT entrenados. El énfasis principal recae en las cuatro clases minoritarias críticas (MN, L, FT, PO) que el modelo baseline no puede detectar. Las matrices de confusión individuales permiten identificar patrones sistemáticos de clasificación errónea. Las diferencias entre modelos se someten a la **prueba de McNemar** Johnson2019-ClassImbalance para determinar significancia estadística ($\alpha = 0.05$).

- **Análisis de interpretabilidad:** Aplicación de LIME Ribeiro2016-LIME y SHAP Lundberg2017-SHAP sobre el modelo BERT entrenado con el mejor método de balanceo identificado, para extraer las características lingüísticas (palabras, n-gramas, patrones sintácticos) con mayor valor predictivo por categoría NFR. Este análisis permite identificar qué rasgos del texto técnico diferencian categorías como Tolerancia a Fallos y Mantenibilidad, y por qué el modelo comete errores sistemáticos en determinadas clases.

5.0.9 Técnicas de Muestreo

La técnica de muestreo empleada es de tipo **no probabilístico e intencional**. El dataset PROMISE NFR fue seleccionado de manera razonada como muestra representativa de la tarea de clasificación multi-clase de NFRs, por ser el único benchmark del dominio con las siguientes características simultáneas: 12 categorías etiquetadas, desbalance extremo documentado (278:1), resultados de referencia publicados con BERT, y disponibilidad pública sin restricciones ClelandHuang2007-PROMISE, BenAmmar2025-TAOS.

El *split* train/test sigue la partición exacta del trabajo de referencia (70/30, 1,073 instancias de entrenamiento y 461 de prueba), garantizando que los resultados de esta investigación sean directamente comparables con los reportados por BenAmmar2025-TAOS. Esta decisión es metodológicamente necesaria: cualquier cambio en la partición introduciría una variable de confusión que impediría atribuir las diferencias en F1-score al método de generación de datos.

Los datos sintéticos generados por cada método se añaden **únicamente al conjunto de entrenamiento**; el conjunto de prueba permanece intacto y sin augmentación en todos los experimentos, asegurando que la evaluación del desempeño clasificatorio se realice siempre sobre distribución real Wei2019-EDA, BenAmmar2025-TAOS.

5.1 Aspectos Éticos

La presente investigación trabaja exclusivamente con **datos textuales de dominio público**: el dataset PROMISE NFR ClelandHuang2007-PROMISE, disponible en Zenodo bajo licencia abierta, y los datos sintéticos generados computacionalmente a partir de él. No se recopila, procesa ni almacena ningún dato personal identificable de usuarios ni de desarrolladores de software. Los requerimientos del dataset son textos técnicos anonimizados extraídos de documentos SRS públicos, sin información sensible de ningún tipo.

5.1.1 Anonimato y Confidencialidad

El dataset PROMISE NFR no contiene información personal identificable. Los requerimientos son fragmentos de especificaciones técnicas de software ya publicadas en la literatura académica ClelandHuang2007-PROMISE. Los datos sintéticos generados por los cuatro métodos son textos artificiales sin correlato con personas reales. En consecuencia, no existe riesgo de violación de privacidad ni de confidencialidad en ninguna fase del estudio.

5.1.2 Uso Responsable de los Modelos de IA Generativa

El uso de las APIs de OpenAI (GPT-4) y Anthropic (Claude) para la generación de datos sintéticos se realizará de conformidad con los términos de uso de cada plataforma, que permiten explícitamente el uso para fines de investigación académica. Los *prompts* diseñados en esta investigación no incluirán instrucciones para generar contenido dañino, engañoso ni éticamente problemático. La generación se limita estrictamente a requerimientos de software técnicos dentro del vocabulario del dominio de IS.

5.1.3 Reproducibilidad y Transparencia

Todo el código fuente de los experimentos —incluyendo los scripts de generación de datos, los pipelines de entrenamiento BERT, los análisis estadísticos y los módulos de interpretabilidad LIME/SHAP— será publicado en un repositorio público (GitHub) con licencia abierta, junto con instrucciones detalladas para la reproducción completa de los resultados. La semilla global (`SEED=42`) está fijada en todos los procesos estocásticos, garantizando que los resultados sean reproducibles de forma exacta en el mismo entorno de hardware y software.

5.1.4 Riesgo Ético Nulo

El estudio presenta riesgo ético nulo dado que: (a) no involucra seres humanos como sujetos de investigación; (b) no recopila datos personales; (c) trabaja exclusivamente con un dataset de dominio público y con texto generado computacionalmente; y (d) no tiene impacto sobre sistemas de software en producción. La investigación es puramente computacional y académica, orientada a avanzar el estado del arte en la clasificación automática de NFRs.

5.1.5 Conflictos de Interés

Los autores declaran no tener conflictos de interés financieros, académicos ni institucionales que puedan influir en el diseño, la ejecución, el análisis ni la presentación de los resultados de esta investigación. El trabajo no cuenta con financiación externa de empresas tecnológicas, incluyendo OpenAI o Anthropic.
sectionCronograma de actividades y presupuesto

5.2 Cronograma de actividades

La Figura 1 presenta el flujo metodológico general del proyecto organizado en cinco fases principales, siguiendo directrices recientes en aumentación de datos, procesamiento de lenguaje natural y aprendizaje automático aplicadas a la clasificación de Requerimientos No Funcionales (NFR). Cada fase integra actividades específicas como recopilación y preparación del dataset PROMISE NFR, implementación de los métodos de aumentación (EDA, SMOTE-Tomek, TAOS e IA Generativa), fine-tuning de BERT, evaluación comparativa con validación cruzada de 5 pliegues y análisis de interpretabilidad con LIME y SHAP. Este cronograma permite visualizar la secuencia lógica del estudio, asegurando una ejecución progresiva, coherente y alineada con los objetivos de clasificación fina de NFR planteados en la investigación.

5.3 Presupuesto Proyectado

El proyecto requiere recursos tecnológicos, servicios en la nube, acceso a modelos de lenguaje de gran escala y soporte institucional para garantizar la ejecución adecuada de las cinco fases metodológicas. Diversos estudios destacan que el fine-tuning de modelos transformer como BERT, la aumentación de texto con técnicas como EDA y TAOS, y la validación experimental con validación cruzada estratificada exigen infraestructura computacional de

alto rendimiento, en particular unidades de procesamiento gráfico (GPU) para reducir tiempos de entrenamiento [1–3].

Asimismo, investigaciones recientes en clasificación de NFR y generación de datos sintéticos señalan que la ejecución de modelos de lenguaje como GPT-4 y Claude mediante prompting, la gestión de embeddings BERT de 768 dimensiones y la interpretabilidad con LIME y SHAP requieren entornos de cómputo adecuados, conectividad estable y herramientas de análisis especializadas [4–6].

El presupuesto proyectado considera recursos indispensables para el entrenamiento de modelos, generación de datos sintéticos, redacción del artículo científico, revisión institucional y procesos de publicación. A continuación, se presenta el detalle de los costos estimados para el periodo enero–noviembre 2026.

Table 1: Presupuesto proyectado del estudio (enero–noviembre 2026)

Categoría	**Monto (S/)**	**Periodo**	**Descripción resumida**
Equipo de cómputo con GPU	4,200	Ene–Mar 2026	Estación de trabajo con GPU dedicada (mínimo 8 GB VRAM) para fine-tuning de BERT base uncased, extracción de embeddings [CLS] de 768 dimensiones y ejecución de los 5 pipelines experimentales en los 5 pliegues de validación cruzada.
Servicios en la nube GPU (Google Colab Pro / AWS)	1,200	Feb–May 2026	Instancias con GPU T4/A100 para entrenamiento de BERT (Baseline, EDA, SMOTE-Tomek, TAOS, IA Generativa), estimado en 3–8 horas por método según complejidad del pipeline de aumentación.
API de IA Generativa (GPT-4 / Claude)	1,800	Mar–May 2026	Créditos de uso de la API de OpenAI (GPT-4) y Anthropic (Claude) para generación de requerimientos sintéticos mediante few-shot prompting en el OE4 de IA Generativa.
Gestión y preparación del dataset	400	Ene 2026	Descarga, verificación y preprocesamiento del dataset PROMISE NFR desde el repositorio oficial de TAOS, preparación de train.csv y test.csv para los 5 pliegues de validación cruzada estratificada.
Herramientas de IA para redacción científica (ChatGPT, DeepL)	960	Ene–Jun 2026	Suscripciones para traducción técnica del abstract, revisión del inglés científico, apoyo en redacción de secciones del artículo y generación de visualizaciones comparativas de resultados.
Licencias de software especializado	600	Feb–Abr 2026	JetBrains (PyCharm Pro) para desarrollo de notebooks Jupyter, y herramientas estadísticas para análisis de significancia (prueba de McNemar) y generación de figuras de interpretabilidad LIME/SHAP.
Internet banda ancha dedicada	540	Feb–May 2026	Conectividad de alta velocidad para descarga de modelos BERT preentrenados (440 MB), acceso remoto a Google Colab, transferencia de checkpoints y uso de APIs de IA Generativa.
Servicios de traducción técnica	250	Jun 2026	Revisión profesional del abstract y corrección del inglés técnico del short paper previo a su envío a conferencia o revista indexada.
Inscripción académica del proyecto	900	Ene 2026	Registro institucional obligatorio en la Universidad Peruana Unión para habilitar oficialmente el inicio del proyecto de tesis.
Dictaminación académica UPeU	1,800	Ago–Sep 2026	Evaluación metodológica, técnica y conceptual por el comité dictaminador de la Escuela Profesional de Ingeniería de Sistemas.
Cierre metodológico del proyecto	2,100	Oct 2026	Verificación final del informe de tesis, anexos experimentales (notebooks Jupyter, JSONs de resultados, figuras LIME/SHAP), cumplimiento metodológico y cierre institucional.
Publicación científica (APC)	900	Nov 2026	Pago por procesamiento del artículo (APC) para publicación del short paper en revista indexada (Scopus/WoS) o repositorio institucional UPeU.
Total estimado	**15,650**	–	**Costo global proyectado del estudio 2026.**

6 Referencias Bibliográficas

References

[1] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of deep bidirectional transformers for language understanding," in *Proceedings of NAACL-HLT 2019*, 2019, pp. 4171–4186.

[2] B. Ben Ammar and N. F. Almatrafi, "Classification of requirements from software requirement specification documents: TAOS: A novel TextAttack oversampling approach for fine-grained classification of software requirements," *Engineering, Technology & Applied Science Research*, vol. 15, no. 6, pp. 29 872–29 879, 2025.

[3] J. Wei and K. Zou, "EDA: Easy data augmentation techniques for boosting performance on text classification tasks," in *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, Hong Kong, China, 2019, pp. 6382–6388.

[4] OpenAI, "GPT-4 technical report," 2023.

[5] M. T. Ribeiro, S. Singh, and C. Guestrin, ""why should I trust you?": Explaining the predictions of any classifier," in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, pp. 1135–1144.

[6] S. M. Lundberg and S.-I. Lee, "A unified approach to interpreting model predictions," in *Advances in Neural Information Processing Systems*, vol. 30, 2017, pp. 4765–4774.