Revisión Sistemática de la Literatura sobre la Clasificación de Requerimientos No Funcionales con Desbalance de Clases: Aumentación de Datos, BERT y Modelos de Lenguaje de Gran Escala

Andres Lino Montes Mamani, Cristian Cabana Sulca, Alessandro Pastor Mamani Mamani
Escuela Profesional de Ingeniería de Sistemas
Universidad Peruana Unión, Juliaca, Perú
Asesor: Mg. Esteban Tocto Cano

***Resumen*—Contexto. La clasificación automática de requerimientos no funcionales (NFR) está limitada por el desbalance extremo de clases, y la literatura ofrece técnicas de aumentación de datos, clasificadores basados en BERT y modelos de lenguaje de gran escala (LLM) sin compararlos de forma controlada. Objetivo. Identificar, evaluar y sintetizar la evidencia sobre las técnicas contra el desbalance en la clasificación de NFR, los clasificadores con los que se combinan, el uso de LLM como clasificadores, las fuentes de datos y el rigor con que se evalúan. Método. Revisión sistemática según las guías de Kitchenham y Charters y la declaración PRISMA 2020, con búsquedas en Scopus, Web of Science, IEEE Xplore y ACM Digital Library (2017–2026), criterios explícitos de selección, validación del cribado por dos revisores, evaluación de calidad con ocho criterios y extracción de datos del texto completo. Resultados. [se completan tras la extracción del texto completo]. Conclusiones. [se completan tras la síntesis].**

***Index Terms*—revisión sistemática, requerimientos no funcionales, desbalance de clases, aumentación de datos, BERT, modelos de lenguaje de gran escala**

I. Introducción

Los requerimientos no funcionales (NFR) expresan atributos de calidad como la seguridad, el desempeño, la portabilidad o la tolerancia a fallos, y su clasificación automática a partir de las especificaciones de software es una tarea consolidada en la ingeniería de requerimientos [1]–[3]. El principal obstáculo es el desbalance de clases: en la partición de entrenamiento que usa TAOS [4], la clase funcional tiene 557 requerimientos y portabilidad, solo dos.

El estado del arte asociado a esta investigación mostró que la aumentación de datos, los clasificadores basados en BERT y los LLM se han estudiado por separado. Cada estudio evalúa una única técnica contra el desbalance, y los LLM se comparan con transformers que no fueron entrenados con datos aumentados. Aquel análisis se basó en los resúmenes de los estudios de una sola base de datos. Esta revisión sistemática amplía la búsqueda a cuatro bases, valida la selección con dos revisores, evalúa la calidad de cada estudio y extrae los datos del texto completo, de modo que las brechas queden respaldadas por evidencia verificable.

Tabla I
Alcance de la revisión según el esquema PICOC

Elemento	Definición
Población	Estudios que clasifican automáticamente requerimientos de software escritos en lenguaje natural en tipos de requerimiento o atributos de calidad.
Intervención	Técnicas contra el desbalance y la escasez de datos (remuestreo tipo SMOTE y SMOTE-Tomek, aumentación léxica tipo EDA, TextAttack y TAOS, retrotraducción, generación con LLM, funciones de pérdida ponderadas) y clasificadores basados en transformers o en LLM.
Comparación	Clasificadores entrenados sin tratamiento del desbalance, aprendizaje automático clásico y transformers ajustados sin aumentación.
Resultados	F1 macro, F1 ponderado, F1 por clase y MCC; desempeño en las clases minoritarias; rigor del protocolo de evaluación.
Contexto	Ingeniería de requerimientos; conjuntos como PROMISE, PROMISE_exp, PURE y SecReq, y texto de usuarios o de proyectos de código abierto.

La Sección II describe el protocolo, la III presenta los resultados por pregunta de investigación, la IV los discute, la V analiza las amenazas a la validez y la VI concluye.

II. Protocolo de la revisión

La revisión sigue las guías para revisiones sistemáticas en ingeniería de software de Kitchenham y Charters [5], [6] y reporta el proceso conforme a la declaración PRISMA 2020 [7].

II-A. Preguntas de investigación

La Tabla I delimita el alcance con el esquema PICOC y la Tabla II formula las preguntas de investigación.

II-B. Fuentes y cadenas de búsqueda

Se consultaron cuatro bases de datos: Scopus, Web of Science Core Collection, IEEE Xplore y ACM Digital Library. En cada una se aplicaron cuatro cadenas equivalentes (Tabla III). Todas comparten un bloque común que combina los términos referidos a requerimientos no funcionales, de calidad o de

Tabla II
PREGUNTAS DE INVESTIGACIÓN

ID	Pregunta y motivación
PR1	¿Qué enfoques de clasificación se aplican a los NFR y cómo han evolucionado? *Sitúa el desempeño de BERT y de los LLM frente a los métodos previos.*
PR2	¿Qué técnicas se usan contra el desbalance y la escasez de datos, con qué clasificadores y con qué efecto en las clases minoritarias? *Núcleo de la comparación entre TAOS, EDA y SMOTE-Tomek.*
PR3	¿Cómo se usan los LLM como clasificadores de requerimientos y frente a qué se comparan? *Fundamenta la comparación con BERT aumentado.*
PR4	¿Qué conjuntos y fuentes de datos se emplean y cómo se amplían? *Respalda la ampliación con requerimientos de GitHub.*
PR5	¿Con qué rigor se evalúan los estudios (partición, fuga de datos, métricas por clase, pruebas estadísticas, reproducibilidad)? *Determina la confianza que merece la evidencia.*

Tabla III
REGISTROS RECUPERADOS POR BASE DE DATOS Y EJE TEMÁTICO

Base	Aum.	BERT	LLM	Ampl.	Total
Scopus	84	214	173	94	565
Web of Science	[]	[]	[]	[]	[]
IEEE Xplore	[]	[]	[]	[]	[]
ACM DL	[]	[]	[]	[]	[]
Total					[]

software con el concepto de clasificación, y cada cadena añade uno de los ejes temáticos de la revisión. Donde la base lo permite, se emplean operadores de proximidad para evitar siglas ambiguas como SRS o EDA. Los filtros comunes son el periodo 2017–2026, los idiomas inglés y español, y los tipos artículo, ponencia, revisión y capítulo de libro. Las cadenas completas figuran en el Anexo A. Las búsquedas en Scopus se realizaron en octubre de 2026 y las de las demás bases, en [fecha].

II-C. Criterios de selección

La Tabla IV define los criterios. Un estudio se incluye si cumple los cuatro criterios de inclusión (CI) y se excluye si cumple cualquiera de exclusión (CE). El texto de usuarios (reseñas, solicitudes, issues) solo se incluye cuando las clases son tipos de requerimiento o atributos de calidad. Cuando el título y el resumen no bastan para decidir, el estudio pasa a la lectura del texto completo.

II-D. Proceso de selección y fiabilidad

La selección tiene tres etapas: eliminación de duplicados entre bases y cadenas, cribado por título y resumen, y evaluación de elegibilidad con el texto completo (Fig. 1). El cribado inicial se realizó con apoyo de un modelo de lenguaje, y cada decisión se documentó junto con el criterio aplicado. Para evaluar su fiabilidad, dos autores revisaron de forma independiente y ciega una muestra formada por todos los estudios incluidos y el 20 % de los excluidos. Cada uno trabajó con un orden aleatorio distinto y sin conocer las decisiones

Tabla IV
CRITERIOS DE INCLUSIÓN (CI) Y EXCLUSIÓN (CE)

Código	Criterio
CI1	Estudio primario que clasifica automáticamente texto de requerimientos en tipos de requerimiento (FR/NFR o subclases de NFR) o en atributos de calidad.
CI2	Usa aprendizaje automático, aprendizaje profundo, transformers o LLM.
CI3	Reporta una evaluación empírica cuantitativa.
CI4	Publicado entre 2017 y 2026, en inglés o español.
CE1	Fuera del dominio de software: *requirement* o *quality* se usan con otro sentido.
CE2	Otra tarea de ingeniería de requerimientos o de software (ambigüedad, trazabilidad, generación, priorización, riesgo, bugs), o clases que no son tipos de requerimiento.
CE3	Sin evaluación empírica.
CE4	Estudio secundario: se usa como contexto, no en la síntesis.
CE5	Duplicado, o versión resumida o extendida de otro registro.

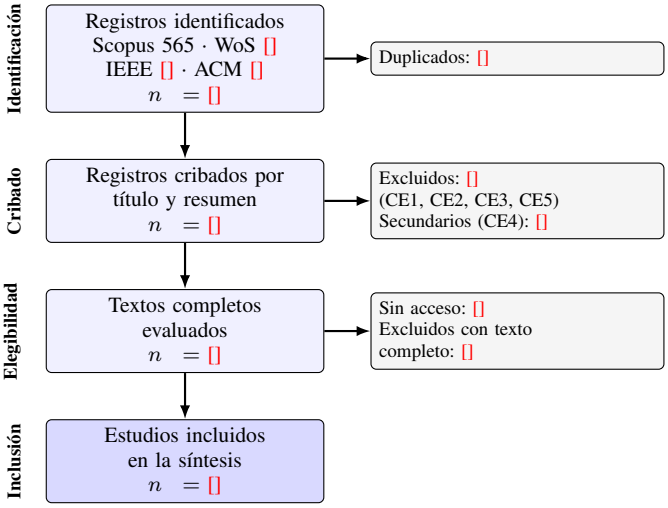


Fig. 1. Diagrama de flujo PRISMA 2020 de la selección de estudios.

del cribado inicial ni las del otro revisor. El acuerdo entre los tres evaluadores, medido con el kappa de Fleiss, fue κ = [por completar], y el kappa de Cohen entre pares osciló en [por completar]. Los desacuerdos se resolvieron por mayoría y discusión.

En la fase realizada en Scopus, los 565 registros se redujeron a 434 tras eliminar 131 duplicados entre cadenas. El cribado por título y resumen excluyó 277 (142 por CE1, 129 por CE2, 4 por CE3 y 2 por CE5), identificó 12 estudios secundarios y retuvo 145 estudios primarios para la lectura del texto completo.

II-E. Evaluación de la calidad

La calidad de cada estudio incluido se evaluó con ocho criterios (Tabla V), adaptados de Dybå y Dingsøyr [8] y de las guías de Kitchenham y Charters [5] al problema de la clasificación con desbalance. Cada criterio se puntúa con 1 (sí), 0.5 (parcialmente) o 0 (no), lo que da un total entre 0

Tabla V
CRITERIOS DE EVALUACIÓN DE LA CALIDAD

ID	Criterio
QA1	Los objetivos o las preguntas de investigación están claramente definidos.
QA2	El conjunto de datos está descrito: origen, tamaño, clases y su distribución.
QA3	El protocolo de evaluación está descrito y evita la fuga de datos: la aumentación se aplica solo al entrenamiento y no hay duplicados entre entrenamiento y prueba.
QA4	Usa métricas adecuadas para el desbalance (F1 macro, F1 por clase o MCC).
QA5	Compara contra una línea base o contra el estado del arte.
QA6	Reporta variabilidad o pruebas de significancia estadística.
QA7	Es reproducible: código, datos e hiperparámetros disponibles o descritos.
QA8	Discute limitaciones o amenazas a la validez.

y 8. La puntuación no se usó para excluir estudios, sino para ponderar la evidencia en la síntesis. Dos autores revisaron de forma independiente el 20 % de las evaluaciones.

II-F. Extracción y síntesis de datos

Los datos se extrajeron del texto completo con un formulario estandarizado de 23 campos, agrupados en cinco bloques: datos y tarea (fuente del texto, conjunto, idioma, número de requerimientos y de clases, distribución de clases), tratamiento del desbalance (técnica y si la aumentación se aplica solo al entrenamiento), clasificación (clasificadores y papel del LLM), evaluación (protocolo, control de duplicados, métricas, F1 macro, ponderado y de las clases minoritarias, línea base y pruebas estadísticas) y reproducibilidad (disponibilidad de código y datos, y limitaciones declaradas). Dado que los estudios difieren en conjuntos, clases, particiones y métricas, no procede un metaanálisis. La síntesis es narrativa y tabular por pregunta de investigación, y la evidencia se pondera según la puntuación de calidad.

III. RESULTADOS

III-A. Estudios seleccionados

[Tras unificar las cuatro bases, describir el número de estudios incluidos, su distribución por año, tipo de publicación y fuente, y la puntuación de calidad.]

III-B. PR1: enfoques de clasificación

[Síntesis a partir del formulario de extracción.]

III-C. PR2: técnicas contra el desbalance

[Síntesis a partir del formulario de extracción.]

III-D. PR3: LLM como clasificadores

[Síntesis a partir del formulario de extracción.]

III-E. PR4: conjuntos y fuentes de datos

[Síntesis a partir del formulario de extracción.]

III-F. PR5: rigor de la evaluación

[Síntesis de los criterios QA1–QA8. Se incluirá la verificación de la partición pública de TAOS: el 52 % de sus requerimientos de prueba también figura en entrenamiento y sus 1,534 filas corresponden a 988 requerimientos distintos.]

IV. DISCUSIÓN

[Interpretación de los resultados, implicaciones para la investigación propuesta y comparación con el estado del arte.]

V. AMENAZAS A LA VALIDEZ

Validez de constructo. Las cadenas de búsqueda pueden omitir estudios que describen la tarea con otros términos. Para mitigarlo, se combinaron cuatro ejes temáticos, se emplearon sinónimos y variantes ortográficas y se usaron operadores de proximidad.

Sesgo de selección. El cribado inicial se realizó con apoyo de un modelo de lenguaje. Para controlarlo, dos autores validaron de forma independiente y ciega una muestra de las decisiones, se midió el acuerdo con kappa y se documentó el criterio aplicado a cada registro.

Sesgo de publicación. La revisión incluye solo literatura indexada en cuatro bases; pueden faltar estudios con resultados negativos o publicados en otros medios.

Validez de la extracción. La extracción la realizó un revisor con un formulario estandarizado; dos autores revisaron una muestra.

Validez de las conclusiones. La heterogeneidad de conjuntos, clases y métricas impide comparar cifras entre estudios; por ello, la síntesis es narrativa y se pondera por calidad.

VI. CONCLUSIONES

[Respuesta breve a cada pregunta de investigación y brechas confirmadas.]

Disponibilidad de datos. Las cadenas de búsqueda, las decisiones de cribado con el criterio aplicado, el formulario de extracción y el código del análisis están disponibles en el repositorio del proyecto (https://github.com/AlessandroPastor/research).

REFERENCIAS

[1] J. Cleland-Huang, R. Settimi, X. Zou, and P. Solc, "Automated classification of non-functional requirements," *Requirements Engineering*, vol. 12, no. 2, pp. 103–120, 2007.

[2] Z. Kurtanović and W. Maalej, "Automatically classifying functional and non-functional requirements using supervised machine learning," in *2017 IEEE 25th International Requirements Engineering Conference (RE)*, 2017, pp. 490–495.

[3] T. Hey, J. Keim, A. Koziolek *et al.*, "NoRBERT: Transfer learning for requirements classification," in *2020 IEEE 28th International Requirements Engineering Conference (RE)*, 2020, pp. 169–179.

[4] B. Ben Ammar and N. F. Almatrafi, "Classification of requirements from software requirement specification documents: TAOS: A novel TextAttack oversampling approach for fine-grained classification of software requirements," *Engineering, Technology & Applied Science Research*, vol. 15, no. 6, pp. 29 872–29 879, 2025.

[5] B. Kitchenham and S. Charters, "Guidelines for performing systematic literature reviews in software engineering," Keele University and Durham University, Tech. Rep. EBSE-2007-01, 2007.

[6] B. A. Kitchenham, D. Budgen, and P. Brereton, *Evidence-Based Software Engineering and Systematic Reviews*. Chapman and Hall/CRC, 2015.

[7] M. J. Page, J. E. McKenzie, P. M. Bossuyt *et al.*, "The PRISMA 2020 statement: An updated guideline for reporting systematic reviews," *BMJ*, vol. 372, p. n71, 2021.
[8] T. Dybå and T. Dingsøyr, "Empirical studies of agile software development: A systematic review," *Information and Software Technology*, vol. 50, no. 9–10, pp. 833–859, 2008.

APÉNDICE

ANEXO A. CADENAS DE BÚSQUEDA COMPLETAS

Scopus (Advanced document search)

S1: aumentación y desbalance.

```
TITLE-ABS-KEY ( ( ( "non-functional" OR "non functional" OR nonfunctional OR quality OR NFR OR NFRs ) W/3 requirement* )
OR "software requirement*" OR "requirements specification*" OR "requirement* classification" OR "PROMISE NFR" OR
"PROMISE_exp" ) AND TITLE-ABS-KEY ( classif* OR categori* ) AND TITLE-ABS-KEY ( "data augmentation" OR "text augmentation"
OR "easy data augmentation" OR TextAttack OR TAOS OR "synthetic data" OR "synthetic sample*" OR oversampl* OR
"over-sampling" OR resampl* OR SMOTE OR Tomek OR "class imbalance" OR "imbalanced data*" OR "imbalanced class*" OR
"minority class*" OR "back translation" OR paraphras* ) AND PUBYEAR > 2016 AND PUBYEAR < 2027 AND ( LIMIT-TO (
DOCTYPE,"ar" ) OR LIMIT-TO ( DOCTYPE,"cp" ) OR LIMIT-TO ( DOCTYPE,"re" ) OR LIMIT-TO ( DOCTYPE,"ch" ) ) AND ( LIMIT-TO (
LANGUAGE,"English" ) OR LIMIT-TO ( LANGUAGE,"Spanish" ) )
```

S2: BERT y transformers.

```
TITLE-ABS-KEY ( ( ( "non-functional" OR "non functional" OR nonfunctional OR quality OR NFR OR NFRs ) W/3 requirement* )
OR "software requirement*" OR "requirements specification*" OR "requirement* classification" OR "PROMISE NFR" OR
"PROMISE_exp" ) AND TITLE-ABS-KEY ( classif* OR categori* ) AND TITLE-ABS-KEY ( BERT OR RoBERTa OR DistilBERT OR NoRBERT
OR transformer* OR "pre-trained language model*" OR "pretrained language model*" OR "transfer learning" OR "fine tun*" )
AND PUBYEAR > 2016 AND PUBYEAR < 2027 AND ( LIMIT-TO ( DOCTYPE,"ar" ) OR LIMIT-TO ( DOCTYPE,"cp" ) OR LIMIT-TO (
DOCTYPE,"re" ) OR LIMIT-TO ( DOCTYPE,"ch" ) ) AND ( LIMIT-TO ( LANGUAGE,"English" ) OR LIMIT-TO ( LANGUAGE,"Spanish" ) )
```

S3: LLM como clasificador.

```
TITLE-ABS-KEY ( ( ( "non-functional" OR "non functional" OR nonfunctional OR quality OR NFR OR NFRs ) W/3 requirement* )
OR "software requirement*" OR "requirements specification*" OR "requirement* classification" OR "PROMISE NFR" OR
"PROMISE_exp" ) AND TITLE-ABS-KEY ( classif* OR categori* ) AND TITLE-ABS-KEY ( "large language model*" OR LLM OR LLMs OR
GPT* OR ChatGPT OR "generative AI" OR Llama OR Gemma OR Mistral OR Claude OR "zero-shot" OR "few-shot" OR "in-context
learning" OR prompt* ) AND PUBYEAR > 2016 AND PUBYEAR < 2027 AND ( LIMIT-TO ( DOCTYPE,"ar" ) OR LIMIT-TO ( DOCTYPE,"cp" )
OR LIMIT-TO ( DOCTYPE,"re" ) OR LIMIT-TO ( DOCTYPE,"ch" ) ) AND ( LIMIT-TO ( LANGUAGE,"English" ) OR LIMIT-TO (
LANGUAGE,"Spanish" ) )
```

S4: GitHub y auto-etiquetado.

```
TITLE-ABS-KEY ( ( ( "non-functional" OR "non functional" OR nonfunctional OR quality OR NFR OR NFRs ) W/3 requirement* )
OR "software requirement*" OR "requirements specification*" OR "requirement* classification" OR "PROMISE NFR" OR
"PROMISE_exp" ) AND TITLE-ABS-KEY ( classif* OR categori* ) AND TITLE-ABS-KEY ( GitHub OR "issue tracker*" OR "issue
report*" OR "open source" OR "open-source" OR "semi-supervised" OR "self-training" OR "pseudo-label*" OR "active learning"
OR "weak supervision" OR "dataset construction" OR "gold standard" ) AND PUBYEAR > 2016 AND PUBYEAR < 2027 AND ( LIMIT-TO
( DOCTYPE,"ar" ) OR LIMIT-TO ( DOCTYPE,"cp" ) OR LIMIT-TO ( DOCTYPE,"re" ) OR LIMIT-TO ( DOCTYPE,"ch" ) ) AND ( LIMIT-TO (
LANGUAGE,"English" ) OR LIMIT-TO ( LANGUAGE,"Spanish" ) )
```

Web of Science Core Collection (Advanced search)

W1: aumentación y desbalance.

```
TS=((("non-functional" OR "non functional" OR nonfunctional OR quality OR NFR OR NFRs) NEAR/3 requirement*) OR "software
requirement*" OR "requirements specification*" OR "requirement* classification" OR "PROMISE NFR") AND TS=(classif* OR
categori*) AND TS=("data augmentation" OR "text augmentation" OR "easy data augmentation" OR TextAttack OR TAOS OR
"synthetic data" OR "synthetic sample*" OR oversampl* OR "over-sampling" OR resampl* OR SMOTE OR Tomek OR "class
imbalance" OR "imbalanced data*" OR "imbalanced class*" OR "minority class*" OR "back translation" OR paraphras*) AND
PY=(2017-2026) AND DT=(Article OR "Proceedings Paper" OR Review OR "Book Chapter") AND LA=(English OR Spanish)
```

W2: BERT y transformers.

```
TS=((("non-functional" OR "non functional" OR nonfunctional OR quality OR NFR OR NFRs) NEAR/3 requirement*) OR "software
requirement*" OR "requirements specification*" OR "requirement* classification" OR "PROMISE NFR") AND TS=(classif* OR
categori*) AND TS=(BERT OR RoBERTa OR DistilBERT OR NoRBERT OR transformer* OR "pre-trained language model*" OR
"pretrained language model*" OR "transfer learning" OR "fine tun*") AND PY=(2017-2026) AND DT=(Article OR "Proceedings
Paper" OR Review OR "Book Chapter") AND LA=(English OR Spanish)
```

W3: LLM como clasificador.

```
TS=((("non-functional" OR "non functional" OR nonfunctional OR quality OR NFR OR NFRs) NEAR/3 requirement*) OR "software
requirement*" OR "requirements specification*" OR "requirement* classification" OR "PROMISE NFR") AND TS=(classif* OR
categori*) AND TS=("large language model*" OR LLM OR LLMs OR GPT* OR ChatGPT OR "generative AI" OR Llama OR Gemma OR
Mistral OR Claude OR "zero-shot" OR "few-shot" OR "in-context learning" OR prompt*) AND PY=(2017-2026) AND DT=(Article OR
"Proceedings Paper" OR Review OR "Book Chapter") AND LA=(English OR Spanish)
```

W4: GitHub y auto-etiquetado.

```
TS=((("non-functional" OR "non functional" OR nonfunctional OR quality OR NFR OR NFRs) NEAR/3 requirement*) OR "software
requirement*" OR "requirements specification*" OR "requirement* classification" OR "PROMISE NFR") AND TS=(classif* OR
categori*) AND TS=(GitHub OR "issue tracker*" OR "issue report*" OR "open source" OR "semi-supervised" OR "self-training"
OR "pseudo-label*" OR "active learning" OR "weak supervision" OR "dataset construction" OR "gold standard") AND
PY=(2017-2026) AND DT=(Article OR "Proceedings Paper" OR Review OR "Book Chapter") AND LA=(English OR Spanish)
```

IEEE Xplore (Command Search)

Filtros aplicados en la interfaz: años 2017–2026; tipo de contenido: conferencias, revistas, magazines y libros.

I1: aumentación y desbalance.

```
("non-functional requirement*" OR "nonfunctional requirement*" OR "quality requirement*" OR "software requirement*" OR
"requirements specification*" OR "requirements classification") AND (classif* OR categori*) AND ("data augmentation" OR
"text augmentation" OR "synthetic data" OR oversampling OR SMOTE OR Tomek OR "class imbalance" OR "imbalanced data" OR
TextAttack OR "back translation")
```

I2: BERT y transformers.

```
("non-functional requirement*" OR "nonfunctional requirement*" OR "quality requirement*" OR "software requirement*" OR
"requirements specification*" OR "requirements classification") AND (classif* OR categori*) AND (BERT OR RoBERTa OR
DistilBERT OR transformer* OR "pre-trained language model*" OR "transfer learning" OR "fine-tuning")
```

I3: LLM como clasificador.

```
("non-functional requirement*" OR "nonfunctional requirement*" OR "quality requirement*" OR "software requirement*" OR
"requirements specification*" OR "requirements classification") AND (classif* OR categori*) AND ("large language model*"
OR LLM* OR GPT* OR ChatGPT OR "generative AI" OR "zero-shot" OR "few-shot" OR prompt*)
```

I4: GitHub y auto-etiquetado.

```
("non-functional requirement*" OR "nonfunctional requirement*" OR "quality requirement*" OR "software requirement*" OR
"requirements specification*" OR "requirements classification") AND (classif* OR categori*) AND (GitHub OR "issue report*"
OR "open source" OR "semi-supervised" OR "self-training" OR "pseudo-label*" OR "active learning")
```

ACM Digital Library (Advanced Search, campo Abstract*)*

Las tres filas se combinan con AND. Filtro de fecha de publicación: 2017–2026.

Fila 1 (común):

```
"non-functional requirements" OR "non-functional requirement" OR "nonfunctional requirements" OR "quality requirements" OR
"software requirements" OR "requirements classification" OR "requirements specification"
```

Fila 2 (común):

```
classification OR classify OR classifying OR categorization OR categorizing
```

A1 — Fila 3: aumentación y desbalance.

```
"data augmentation" OR "text augmentation" OR "synthetic data" OR oversampling OR SMOTE OR Tomek OR "class imbalance" OR
"imbalanced data" OR TextAttack OR "back translation"
```

A2 — Fila 3: BERT y transformers.

```
BERT OR RoBERTa OR DistilBERT OR transformer OR transformers OR "pre-trained language model" OR "pretrained language
model" OR "transfer learning" OR "fine-tuning"
```

A3 — Fila 3: LLM como clasificador.

```
"large language model" OR "large language models" OR LLM OR LLMs OR GPT OR ChatGPT OR "generative AI" OR "zero-shot" OR
"few-shot" OR prompting
```

A4 — Fila 3: GitHub y auto-etiquetado.

```
GitHub OR "issue reports" OR "open source" OR "semi-supervised" OR "self-training" OR "pseudo-labeling" OR "active
learning"
```